

中国发债主体信用风险预警模型 — 项目报告（详细版）

作者：章建军 | 日期：2026年8月20日 | 版本：v2.0（教学详细版）
定位：本报告面向"智力正常但对机器学习/信用分析领域较陌生的读者"，从零解释每一个概念——指标是什么、为什么选它；模型是什么原理、为什么用；评价指标怎么读；代码实现的难点在哪里。所有数字均为项目实际运行结果。

目录

- 1. 项目概述：我们到底做了什么
- 2. 数据层：从哪拿数据、怎么拿、拿多少
- 3. 标签层：什么是"信用风险事件"，怎么定义才不算作弊
- 4. 特征层：42个特征逐个解释
- 5. 建模层：WOE分箱 → 逻辑回归 → 评分卡 → XGBoost
- 6. 验证层：凭什么相信模型的结果
- 7. 分析层：分行业画像与预警清单
- 8. 代码实现：难点、坑、与修复
- 9. 结论、局限与展望
- 10. 附录：复现步骤与文件清单

〇、缩写全称对照表（先认识缩写，再读报告）

缩写	英文全称	中文含义	一句话说明
ROE	Return on Equity	净资产收益率	股东每投入1元赚多少；本项目区分力最强指标 (IV=0.99)
ROA	Return on Assets	总资产收益率	全部资产的赚钱效率
EPS	Earnings Per Share	每股收益	每1股赚多少；<0即亏损（标签判定依据）
BPS	Book value Per Share	每股净资产	每1股背后的家底
EBIT	Earnings Before Interest and Taxes	息税前利润	还利息前的利润（利息保障倍数的分子）
EBITDA	Earnings Before Interest, Taxes, Depreciation and Amortization	息税折旧摊销前利润	更接近"经营造血能力"的利润口径

ST	Special Treatment	特别处理	交易所对问题公司的警示标志 (中国版"困境标签")
PD	Probability of Default	违约概率	信贷行业标准术语
WOE	Weight of Evidence	证据权重	把连续数值转换为"风险贡献度"的编码
IV	Information Value	信息量	单个指标对好坏的区分能力(特征筛选用)
LR	Logistic Regression	逻辑回归	可解释的分类模型(本项目主模型)
XGB	eXtreme Gradient Boosting	极端梯度提升	梯度提升树模型 (本项目对照/投产模型)
AUC	Area Under the Curve	ROC曲线下面积	随机抽一对好坏样本, 模型排对顺序的概率
ROC	Receiver Operating Characteristic	受试者工作特征曲线	画"抓中率 vs 冤枉率"的曲线
KS	Kolmogorov-Smirnov statistic	柯尔莫哥洛夫-斯米尔诺夫统计量	好坏累计分布的最大间距(信贷行业标准指标)
FPR	False Positive Rate	假阳性率(冤枉率)	好公司被误判为高风险的比例
TPR	True Positive Rate	真阳性率(抓中率)	坏公司被正确识别的比例
PSI	Population Stability Index	群体稳定性指数	模型上线后分数分布漂移程度
odds	Odds (源自博彩术语)	几率/赔率	$P/(1-P)$: 出险概率与不出险概率之比
PDO	Points to Double the Odds	分数翻倍间隔	分数每增加多少分, odds 翻一倍(本项目20分)
PMML	Predictive Model Markup Language	预测模型标记语言	模型的标准文件格式(跨系统部署用)

RMC_*	Runtime Model Contract (MARVIS平台契约前缀)	运行时模型契约	平台验证要求 notebook 暴露的统一接口 (RMC_SAMPLE_DF 等)
API	Application Programming Interface	应用程序接口	程序之间调用数据的标准方式
CSV	Comma-Separated Values	逗号分隔值	通用表格数据文件格式
HTTP	HyperText Transfer Protocol	超文本传输协议	网页/接口通信的标准协议

1. 项目概述：我们到底做了什么


1.1 一句话版本

用中国 A股上市公司公开的**财务数据**，训练一个机器学习模型，**预测"未来一年这家公司会不会出问题"**（亏损、违约等风险事件），并给出全市场风险排名和预警名单。

1.2 为什么做这件事（业务背景）

- 中国债券市场存量已超120万亿元，2018年以来打破"刚兑"，违约常态化——投资者需要提前识别风险；
- 信用研究（信评）的传统做法是分析师逐家看报表、跑调研——**成本高、覆盖有限**（5000多家公司不可能都看）；
- 本项目的定位是**量化初筛**：模型把5000多家公司先筛一遍，排出风险最高的50家，分析师只需重点看这50家——"模型排序+人工终审"。

1.3 整体流程（一句话看懂全貌）



1.4 三个贯穿全程的原则

原则一：绝不"偷看未来"（防泄漏）。金融建模最大的陷阱是模型在训练时"看到了答案"。本项目用三套机制保证：标签时点对齐、训练集单独拟合、时间序列切分。审计中还发现并修复了一个真实的泄漏bug（见第8章）。

原则二：可解释优先。信用决策要承担责任，黑箱模型无法向业务方解释"为什么拒绝这笔贷款"。因此主模型用逻辑回归+评分卡——每个指标、每个分数都能讲清楚含义。

原则三：独立验证。自己算的指标可能自欺。项目引入开源平台 MARVIS 做"第三方"独立验证：它的内核重新计算所有指标，并校验"训练时的模型"与"要投产的模型文件"是否一致。

2. 数据层：从哪拿数据、怎么拿、拿多少

2.1 数据源（三个，各有分工）

数据源	是什么	本项目用途
akshare	开源Python库（GitHub ★22k），封装了新浪财经/东方财富等免费数据源的接口，把网页数据解析成表格	主力：财务指标（每家公司的历年财报数据）
同花顺 iFinD（HTTP API）	同花顺的金融数据接口，试用账号可用	实际控制人（判断国企/民企）——批量接口一次取20家公司，5,210家约6分钟抓完
巨潮资讯（cninfo）	证监会指定信息披露平台	证监会行业分类（每家公司属于哪个行业）

2.2 样本规模

项	数值	说明
公司数	5,468 家	全部A股剔除金融行业（银行/证券/保险——财务结构特殊，杠杆含义完全不同，混入会污染模型）
时间范围	2019–2025 年报	7年，每年约5,400家
总行数	37,956 行	每行 = "一家公司 × 一个年度"的财务快照
行业覆盖	89%	巨潮证监会分类；未覆盖的11%多为退市/新上市公司
实控人覆盖	91%	iFinD 实控人数据；用于"国企/民企"分组分析

2.3 抓取的工程问题（真实项目的琐碎与必要）

- **为什么需要断点续跑：**5,468家公司逐家请求，每家1–3秒，全量2–3小时。中途任何网络抖动都会中断——把已完成的公司代码写进缓存文件，重启自动跳过，中断可恢复；
- **为什么限速：**akshare 底层是公共免费接口，高频请求会被对方服务器拒绝（报错 RemoteDisconnected）。每次请求间隔0.35秒，失败重试3次、退避等待；
- **数据质量实测发现：**akshare 财务接口的"销售毛利率"列对几乎所有公司返回空值（数据源问题）——实测后从特征中剔除，改用营业利润率/净利率替代。这是真实项目中"数据不是说明书说的那样"的典型情况。

3. 标签层：什么是"信用风险事件"，怎么定义才不算作弊

3.1 机器学习需要什么

监督学习需要"输入-输出"配对：输入是财务特征，输出是**标签**（0=正常，1=出事）。标签定义直接决定模型学什么——这是全项目最核心、最花心思的部分。

3.2 什么是"出事"？（标签定义）

本项目定义"信用风险事件"= 两个事件的并集：

- **首次年度亏损**：公司某年 EPS（每股收益）由正转负。为什么用这个？中国没有美国式破产制度，学术界研究中国公司财务困境的通行标志是ST（特别处理），而 ST 的核心触发条件是"连续两年亏损"。"首次亏损"是这条恶化路径的**第一步**——提前一年捕捉困境起点，这正是"预警"的意义；
- **债券违约**：公司发行的债券发生实质违约。中国债市累计违约发行人309家（联合资信统计，2012–2025），其中A股上市公司子集22家已整理进名单（如华夏幸福2021年违约、康得新2019年违约）。

3.3 时点对齐：怎么定义"预测"才算数（防前视偏差）

关键事实：上市公司的年报最迟在次年4月30日披露。这意味着：

用 *T*年财报（*T*+1年4月30日前可得的信息）→ 预测 *T*+1年内发生的事件

具体实现：对每一行（公司×*T*年财报），标签 *y*=1 当且仅当"该公司首次亏损年份 == *T*+1"（或违约年份 == *T*+1）。

如果违反会怎样？假如用 *T*+1 年的财报去预测 *T*+1 年的事件，模型等于"偷看答案"——训练时 AUC 高达 0.95+，一上线就崩盘。这就是金融时序建模与普通机器学习的本质区别：**时间顺序本身就是数据的灵魂**。

3.4 标签分布（质量检查）

年份（财报年）	2019	2020	2021	2022	2023	2024	合计
正样本（ <i>y</i> =1）	395	278	355	315	358	285	1,986 (5.23%)

正样本占比5.2%——意味着平均每20家公司里约1家会在未来一年首次亏损/违约。分布均匀，没有某一年特别异常（2019年偏高与疫情前经济下行有关，属正常波动）。

4. 特征层：42个特征逐个解释

特征 = 模型用来做判断的"输入变量"。原始财务数据（总资产、净利润、现金流等）不能直接用（公司规模不同不可比），需要加工成**比率**。以下逐个解释每个指标的**公式、含义、直觉方向**（↑表示值越大越安全，↓表示值越大越危险）。

4.1 偿债能力类（6个）——公司扛不扛得住

指标（代码）	计算公式与含义	信用分析直觉
资产负债率 debt_ratio	总负债 ÷ 总资产。总资产里有多少是借来的	↓ 越高越危险。但注意：行业差异大（银行90%正常，制造业70%已很高），所以模型里它是相对比较
流动比率 current_ratio	流动资产 ÷ 流动负债。一年内能变现的资产能否覆盖一年内要还的债	↑ 越高越安全。一般 >1.5 健康，<1 危险
速动比率 quick_ratio	(流动资产-存货) ÷ 流动负债。比流动比率更严格——存货变现慢，剔除后看"真金白银"	↑ 越高越安全
现金比率 cash_ratio	现金及等价物 ÷ 流动负债。最保守——不靠卖资产，光靠手头现金能还多少短债	↑ 越高越安全
利息支付倍数 interest_coverage	EBIT(息税前利润) ÷ 利息费用。赚的钱是利息的几倍	↑ 越高越安全；<2 意味着利润快覆盖不住利息了
产权比率 equity_ratio	总负债 ÷ 所有者权益。杠杆的另一视角：借的钱是股东本金的几倍	↓ 越高越危险

4.2 盈利能力类（7个）——公司赚不赚钱

指标	计算公式与含义	信用分析直觉
净资产收益率 ROE	净利润 ÷ 净资产。股东每投入1元赚多少—— 全项目区分力最强的指标 (IV=0.99)	↑ 越高越安全；出险公司中位数3.4% vs 正常公司7.7%（腰斩）
总资产净利润率 ROA	净利润 ÷ 总资产。不分股东债权人，全部资产的赚钱效率	↑ 越高越安全
销售净利率 net_margin	净利润 ÷ 营业收入。每100元收入最后剩多少利润	↑ 越高越安全；出险公司4.3% vs 正常8.1%
营业利润率 op_margin	营业利润 ÷ 营业收入。主业（不含投资收益/政府补助）的利润率	↑ 越高越安全
成本费用利润率 cost_profit_ratio	利润总额 ÷ (营业成本+费用)。花出去的每1元成本换回多少利润	↑ 越高越安全
每股收益 EPS	净利润 ÷ 总股本。每1股赚多少—— 亏损判定（标签）的直接依据，IV=0.98	↑ 越高越安全；<0 即亏损

每股净资产 BPS	净资产 ÷ 总股本。每1股背后有多少家底	↑ 越高越安全
-----------	----------------------	---------

4.3 现金流质量类（5个）——赚的钱是不是真钱（信评核心逻辑）

为什么现金流单独成类？信用分析的第一原则：**利润是会计判断，现金是事实**。公司可以"做出"利润（赊销、提前确认收入），但现金流骗不了人。经营现金流与利润长期背离的公司，往往是报表粉饰的高危对象。

指标	计算公式与含义	信用分析直觉
每股经营现金流 ocf_per_share	经营活动现金流净额 ÷ 总股本。经营赚到的真金白银，每股摊多少	↑ 越高越安全
经营现金流/销售收入 ocf_to_sales	经营现金流 ÷ 营业收入。每100元收入，有多少变成了真实现金	↑ 越高越安全；长期偏低=利润可能是"纸面利润"
经营现金流/净利润 ocf_to_ni	经营现金流 ÷ 净利润。 利润的"含金量"指标 ——大于1说明利润全部变现，小于1说明利润没收到钱（应收堆积/存货积压）。IV=0.57，模型重点依赖	↑ 越高越安全；长期 <1 是重大警示（信评必看指标）
经营现金流/负债 ocf_to_debt	经营现金流 ÷ 总负债。靠经营造血一年能覆盖多少债务	↑ 越高越安全；出险公司0.068 vs 正常0.140（减半）
现金流量比率 cashflow_ratio	经营现金流 ÷ 流动负债。经营现金流对短债的覆盖	↑ 越高越安全

4.4 营运效率类（3个）——资产转不转得动

指标	计算公式与含义	信用分析直觉
应收账款周转率 ar_turnover	营业收入 ÷ 平均应收账款。应收账款一年转几圈（回款速度）	↑ 越高越安全；周转放慢=客户拖欠=资金被占用
存货周转率 inv_turnover	营业成本 ÷ 平均存货。存货一年卖几轮	↑ 越高越安全；存货积压=滞销=占用资金
总资产周转率 asset_turnover	营业收入 ÷ 总资产。全部资产的"出活"效率	↑ 越高越安全；持续下降=资产效率恶化

4.5 成长类（3个）+ 规模（1个）

指标	计算公式与含义	信用分析直觉
营收增长率 rev_growth	本年营收 ÷ 上年营收 - 1	↑ 一般越高越好，但 <u>异常高增长也可能是激进扩张信号</u> （结合现金流看）
净利润增长率 ni_growth	本年净利 ÷ 上年净利 - 1	↑ 越高越好
总资产增长率 asset_growth	本年总资产 ÷ 上年总资产 - 1	↑ 过高警惕"过度扩张+高杠杆扩张"

总资产（对数） total_assets	ln(总资产)。规模量级；取对数是因为资产跨数量级（亿到万亿），log压缩量纲让模型更稳	↑ 越大越安全（规模效应与"大而不倒"的隐性担保）
-------------------------	--	---------------------------

4.6 趋势特征Δ（6个）——"趋势比水平更重要"

对6个核心指标构造**同比变化**：如 `debt_ratio_delta = 今年负债率 - 去年负债率`。直觉：一个负债率从40%一年飙到65%的公司，比一直65%的公司更危险——**恶化速度是重要信号**。这6个：资产负债率Δ、ROEΔ、经营现金流/净利润Δ、流动比率Δ、净利率Δ、总资产周转率Δ。

4.7 缺失指示变量（_miss, 11个）

缺失率超过5%的列，额外生成一个0/1列标记"该指标是否缺失"。原理：**缺失本身是信息**——指标没披露的公司往往有问题（比如某公司连续不披露经营现金流）。

4.8 特征筛选结果（IV 排序，模型最终只用了25个）

特征	IV	含义解读
ROE	0.987	IV TOP 被盈利类霸榜—— 盈利质量是最强的预警信号 ，与信用分析理论完全一致
EPS	0.976	
ROA	0.954	
净利率	0.599	
成本费用利润率	0.592	
经营现金流/净利润	0.571	现金流含金量——第二大信号源
利息支付倍数	0.379	偿债缓冲
净利润增长率	0.360	盈利趋势

5. 建模层：WOE分箱 → 逻辑回归 → 评分卡 → XGBoost

5.1 第一步：WOE 分箱（把连续数字变成"风险档位"）

5.1.1 问题：为什么不能直接用原始数字？

以负债率为例：模型要学的不是"负债率=76.3%"这个精确数字，而是"负债率处于哪个风险区间"。原因有三：

1. **非线性**：负债率从30%→60%风险缓升，60%→90%风险陡升——直线模型表达不了这种"S型"关系，分箱后用分段常数逼近非线性；
2. **稳健性**：76.3%和76.4%其实没有区别，分箱让模型不被微小波动干扰；
3. **可解释**：分箱后每个区间可以直接读（"负债率70–90%这档风险高"）。

5.1.2 WOE 是什么（证据权重）

把每个特征分成若干箱（本项目等频分箱，10箱），每箱计算：

$$WOE_i = \ln(\text{箱内坏样本占比} / \text{箱内好样本占比}) = \ln((b_i/B) / (g_i/G))$$

其中 b_i/g_i 是第 i 箱内坏/好样本数， B/G 是总体坏/好样本数。直觉：**WOE>0** 表示这箱的"坏浓度"高于整体（更危险），**WOE<0** 表示更安全。WOE 把"负债率 76%"翻译成"风险贡献度 +0.8"——单调、有界、可比。

5.1.3 实现细节（代码难点，第8章详述）

- 缺失值单独成箱（缺失是信息）；
- WOE 平滑：某箱坏样本为0时 $\ln$ 无定义，分子分母各加0.5（拉普拉斯平滑）；
- 分箱只用训练集拟合（防止"看到"验证集）；
- 验证/测试集出现训练集没见过的新数值时，编码为WOE=0（中性处理，不报错）。

5.2 第二步：IV 筛选（哪些特征值得进模型）

$$IV = \sum_i (\text{坏占比}_i - \text{好占比}_i) \times WOE_i$$

IV 度量一个变量"区分好坏的能力"（可以理解为 WOE 的加权和）。经验阈值：IV<0.02 无预测力（剔除）；0.02–0.1 弱；0.1–0.3 中等；>0.3 强。本项目 42 个特征筛出 25 个（IV>0.02）。

5.3 第三步：逻辑回归（主模型）

5.3.1 原理（一步步来）

逻辑回归解决的是"预测0/1"问题。它从线性回归出发：线性回归预测连续值 $y = \beta_0 + \beta_1 x_1 + \dots + \beta_n x_n$ ，但我们要预测的是概率（0到1之间）。于是把线性结果塞进 **Sigmoid 函数**：

$$P(y=1|x) = 1 / (1 + e^{-(\beta_0 + \beta_1 \cdot WOE_1 + \dots + \beta_n \cdot WOE_n)})$$

Sigmoid 把任意实数压缩到(0,1)，变成概率。等价写法（**logit 变换**）：

$$\ln(\text{odds}) = \beta_0 + \beta_1 \cdot WOE_1 + \dots + \beta_n \cdot WOE_n, \text{ 其中 } \text{odds} = P/(1-P)$$

即：模型学的是"风险对数的线性组合"。训练方法：极大似然估计——找到一组系数 β ，使得"对正样本预测的概率高、对负样本预测的概率低"。

5.3.2 为什么选逻辑回归当主模型

- 1. 可解释：系数 β_i 直接读——"经营现金流/净利润恶化一箱，风险对数变化多少"；
- 2. 天然适配 WOE：WOE 变换后特征与 log-odds 近似线性，LR 是最佳搭档（这也是评分卡行业的标准组合）；
- 3. 监管友好：银行风控和监管机构要求模型可解释、可审计，LR+评分卡是行业默认答案。

5.4 第四步：评分卡刻度（把概率翻译成人话）

银行不用概率审批（"违约概率0.031"没人有感觉），用分数（"680分以上通过"）。转换公式：

$$Score = Offset + Factor \times \ln(odds)$$

- 锚点设置：odds=1:1 时 600 分；odds 翻倍分数 +20 分（PDO=20）；
- 推导：Factor = PDO/ln(2) = 20/0.693 = **28.85**；Offset = 600 - 28.85×ln(1) = **600**；
- 本项目分数范围 578–807（训练集），分数越高风险越低——可以直接划准入线（如"650分以下进入人工复核"）。

5.5 第五步：XGBoost（对照模型，效果更优）

5.5.1 原理

XGBoost 是梯度提升决策树：由许多棵"小树"组成加法模型，逐棵训练，每棵新树专门拟合前面所有树的"残差"（错误）：

$$\hat{y} = f_1(x) + f_2(x) + \dots + f_n(x)$$

第 t 轮：先用当前模型预测，计算每个样本的残差（真实值-预测值），然后训练一棵新树 f_t 去拟合残差——相当于"哪里错了补哪里"。每轮目标函数：

$$Obj = \sum 损失(y_i, \hat{y}_i) + \sum 正则(树的复杂度)$$

工程上的三个关键创新：

- 二阶泰勒展开：对损失函数做二阶近似，比普通梯度提升（只用一阶）收敛更快更准；
- 分裂增益公式：每次分裂选择"增益最大"的特征和切分点，带正则项（叶子数、叶子权重）防过拟合；
- 原生处理缺失值：分裂时自动学习"缺失值走左还是右"——本项目 XGB 直接吃含缺失的原始特征，不需要预先填充。

5.5.2 项目中的参数（每个参数为什么这么设）

参数	值	理由
n_estimators	300（固定）	固定轮数而非早停——保证"训练时的模型"与"导出PMML重训的模型"完全一致（平台一致性验证要求，见第6/8章）
max_depth	3	浅树防过拟合（树太深就记住了训练集）
learning_rate	0.05	小步慢走：每棵树只贡献一点点，靠300棵树累积，更稳

subsample / colsample_bytree	0.8 / 0.8	行/列随机采样（类似随机森林思想），每棵树看到不同子集，增强泛化
scale_pos_weight	≈16	正样本只占5.2%，给正样本加权（负/正比），等价于少数类过采样，防止模型"全都预测0"
n_jobs=1, random_state=42	—	确定性训练：同样的输入永远同样的输出（PMML一致性前提）

5.5.3 为什么"双模型"

LR 可解释但表达力有限；XGB 效果好（测试集 AUC 0.885 vs LR 0.864）但是黑箱。业界真实做法是**两者并存**：XGB 用于自动化初筛（量大、要效果），LR评分卡用于需要解释的环节（监管、人工复核）。本项目主交付是可解释链路，XGB 作对照并承担平台投产验证（PMML 工程可行性）。

5.6 模型结果（本地评估）

模型	训练集 AUC/KS	验证集 AUC/KS	测试集 AUC/KS
WOE逻辑回归	0.815 / 0.477	0.820 / 0.487	0.864 / 0.596
XGBoost	0.912 / 0.673	0.850 / 0.555	0.885 / 0.639

观察：训练集与测试集指标接近（甚至测试更好）——**没有过拟合**；测试集（2024年）略优于验证集（2023年），因为2024年事件特征更清晰（地产出清尾声、亏损公司财务恶化更彻底）。

6. 验证层：凭什么相信模型的结果

6.1 时间序列切分（为什么不用随机划分）

常规机器学习用随机抽样划分训练/测试集。金融数据**不行**：同一家公司的相邻年份高度相关（2020年亏损的公司2021年大概率还差），随机划分等于把"邻居"分别放进训练和测试——模型其实见过类似样本，指标虚高。正确做法：

时间线（财报年）：2019 2020 2021 2022 | 2023 | 2024+2025

 └── 训练 ─┘ └ 验证 ┘ └ 样本外 ┘

训练：拟合模型；验证：调参（只看一次）；样本外：最终检验（模型从未见过）

6.2 评估指标逐个解释

AUC（曲线下面积）

最直观的解释：随机抽一个"真出事"的公司和一个"真没事"的公司，模型给前者打分更高的概率。0.5=瞎猜（抛硬币），0.7=可用，0.8=强区分，0.9+=极强。本项目测试集 XGB AUC=0.885——意思是约88.5%的情况下，模型能把"出事的"排在"没事的"前面。

KS（Kolmogorov-Smirnov）

把所有公司按模型分数从低到高排序，画两条累计曲线：坏样本占比、好样本占比。两条曲线的**最大间距**就是KS：

$$KS = \max | \text{坏样本累计占比} - \text{好样本累计占比} |$$

直觉：KS=0.64 意味着在最优切点处，模型能分离出64%的"好坏分布差距"。信贷行业标准：KS>0.3 可用，>0.4 优秀，>0.6 极强（但过高要警惕过拟合）。

PSI（群体稳定性指数）

模型上线后会"漂移"吗？PSI 比较两个时期分数分布的差异：

$$PSI = \sum (\text{实际占比} - \text{预期占比}) \times \ln(\text{实际占比} / \text{预期占比})$$

阈值：<0.1 稳定；0.1-0.25 需关注；>0.25 需重建模型。本项目月度 PSI vs 训练 = **0.02**——2023-2025年评分分布几乎没变，模型稳定。

IV（见5.2）

变量区分度，用于特征筛选。

6.3 平台独立验证（MARVIS：让第二套独立计算来背书）

MARVIS 是开源风控建模验证平台（MIT协议）。它的作用不是建模，而是**验证**：

- Notebook 契约**：建模notebook必须在顶层暴露统一接口（样本、标签列、打分函数、算法名）——强制"模型可复现、可调用"，杜绝模型藏在代码角落的演示型项目；
- 独立计算**：平台用自己实现的确定性内核，对模型重新计算 KS/AUC/PSI/分箱/压力测试——**两套独立代码算出相近结果才算数**（本地 0.885 vs 平台 0.882，互相印证）；

3. **PMML 一致性**：把训练好的模型导出为标准 PMML 文件（模型上线时的实际交付格式），平台逐行比对"内存模型打分"与"PMML文件打分"——37,956行**零失败**，证明"我训练的模型"和"我声称要投产的文件"是同一个；
4. **压力测试**：按特征类别整类剔除后重算 KS，看模型对哪类特征"上瘾"：

剔除的特征类别	剔除后 KS	KS 变化	解读
（基线）	0.632	—	样本外基线
盈利类	0.106	−0.526	模型核心依赖盈利质量——符合理论
偿债类	0.609	−0.023	次要但真实贡献
现金流类	0.620	−0.011	次要贡献
成长类	0.628	−0.004	弱贡献

6.4 平台验证的最终成绩单

数据集	AUC	KS	说明
训练（2019–2022）	0.912	0.671	平台独立计算
开发验证（2023）	0.850	0.555	平台独立计算
样本外（2024+2025）	0.882	0.632	平台独立计算（2025年行为"未来"前瞻样本）
PMML一致性	37,956 行全部成功、零失败、零空值		
月度PSI vs 训练	0.02（优秀线 0.1）		

7. 分析层：分行业风险画像与预警清单

7.1 方法一：透视表（行业×年份风险矩阵）

把样本按"行业×年份"分组，计算每组的风险事件发生率（正样本比例）。结果（2019–2024整体风险率TOP10）：

行业	风险率	解读
建筑装饰、装修	13.2%	地产链：垫资施工、应收高企
广播、电视、电影	11.8%	可选消费 + 高经营杠杆
黑色金属冶炼（钢铁）	10.6%	周期下行、产能过剩
房地产业	10.5%	2021–2024违约潮主战场
商务服务/公共设施/软件/文教/环保/纺织	8.1–8.9%	弱现金流、可选属性

发现：高风险行业=地产链 + 周期 + 弱现金流行业，与中国债市实际违约分布完全吻合。

7.2 方法二：出险画像（出险 vs 正常公司的指标中位数对比）

把"未来一年出险"的公司（出险前一年的财报）与正常公司分组，比较各指标**中位数**（为什么用中位数？财务指标右偏、极端值多，均值易被污染，中位数稳健）：

指标	出险公司	正常公司	差异
ROE(%)	3.37	7.74	腰斩
净利率(%)	4.26	8.11	腰斩
每股收益(元)	0.18	0.40	腰斩
经营现金流/负债	0.068	0.140	减半
资产负债率(%)	40.1	39.8	几乎无差异
流动比率	1.82	1.84	几乎无差异

核心结论：盈利与现金流质量的恶化是比杠杆更早、更强的预警信号。杠杆类水平指标在出险前几乎无区分度——因为上市公司普遍在报表层面维持杠杆指标；而盈利与现金流的恶化先于违约发生。这条结论被三套独立证据支持：IV排序（盈利类霸榜）、压力测试（剔盈利类模型崩溃）、画像统计（盈利腰斩）——三个证据指向同一个规律，这是建模可信度的最高形态。

7.3 所有制维度

- 民企风险率 6.5% > 国企 5.8% > 无实控人 4.3%；
- 与联合资信统计一致（2025年新增违约主体69%为民营企业）；

- 高风险组合示例：畜牧业民企16.7%（正邦、雏鹰等养殖周期股）、钢铁国企13.5%（行业周期而非所有制）、地产国企10.8%。

7.4 预警清单 TOP50（模型的实际输出）

对最新一期（2025年报）全样本打分，取风险最高50家，并按画像规则标注主要风险特征（阈值来自7.2的中位数）。TOP10：

代码	名称	行业	所有制	预警概率	主要风险特征
920931	无锡鼎邦	专用设备	—	0.944	ROE<3%；净利率<4%；现金流/负债<5%
300342	天银机电	通用设备	民企	0.942	ROE<3%；净利率<4%；现金流覆盖弱
600248	陕建股份	土木工程建筑	国企	0.936	盈利双低；现金流覆盖弱；负债率>70%
600740	山西焦化	焦化	国企	0.932	盈利双低；现金流覆盖弱
600328	中盐化工	化学原料	国企	0.925	盈利双低；现金流覆盖弱
600510	黑牡丹	房地产	民企	0.922	盈利双低；现金流覆盖弱
600010	包钢股份	钢铁	国企	0.915	盈利双低；现金流覆盖弱
002419	天虹股份	零售	国企	0.915	盈利双低；负债率>70%
002135	东南网架	金属制品	民企	0.920	盈利双低；现金流覆盖弱
688075	安旭生物	医药	民企	0.925	ROE<3%；现金流覆盖弱

名单结构：民企占72%；行业集中在软件/电气机械/建筑/钢铁化工——与画像结论完全自洽；90%+的公司同时命中"盈利双低"与"现金流覆盖弱"——这就是模型学到的规律：盈利腰斩+利润不变现。

名单的使用边界（诚实声明）：① 预警概率是"风险事件（首次亏损/违约）"概率，不是违约概率——违约是更小的尾部；② 排序可信、断言不可信（测试集AUC 0.885证明排序有效，但不能说某家"一定违约"）；③ 模型看不见报表粉饰与表外负债——名单的正确用法是"启动人工尽调"，不是"直接定罪"；④ 城投/非上市主体不在样本。

8. 代码实现：难点、坑、与修复

8.1 工程难点总览

难点	问题本质	解决方案
全量抓取中断	5,468家x网络请求，2-3小时，任何抖动都会失败	断点续跑（缓存已完成代码）+ 限速0.35s + 失败重试3次退避
代码前导零丢失	股票代码"000002"被 pandas 读成整数2	read_csv 强制 dtype=str + zfill(6)
WOE分箱索引错乱	pd.cut 后 groupby().groups 返回的是原始索引而非位置索引，误用位置索引导致 IndexError	直接用 groups 返回的索引取值（调试两次定位）
布尔取反的隐蔽bug	含NaN的列 fillna(False) 后是 object 类型，~ 取反行为异常	显式 .astype(bool) 后再取反
测试集值超出训练分箱边界	pd.cut 对边界外的值返回 NaN → 模型收到空值报错	编码后 fillna(0.0)——边界外值按"无信息"（WOE=0）处理，业界标准做法
评分卡刻度	分数映射公式推导与实现	Score = Offset + Factor×ln(odds), PDO=20锚点600
PMML与内存模型不一致	PMML重训若用早停，轮数不确定→与内存模型不同→一致性验证失败	固定300轮 + n_jobs=1 + 固定种子（确定性训练）
macOS缺Java	PMML评分运行时（pypmml）需要Java，本机没有	下载OpenJDK17（清华镜像180MB）并设置JAVA_HOME

8.2 审计发现的两个真实bug（本报告最诚实的部分）

Bug 1: 标签泄漏（严重）

特征工程中"缺失率>5%的列自动生成缺失指示变量"的规则，把**违约名单年份列（default_year）**也生成了缺失指示——而该列的缺失与否**恰好精确标记"这家公司在不在违约名单里"**（56行default_year_miss=0全是违约公司）。模型如果学到这个特征，等于直接"记住名单"而不是学习财务规律。审计时通过交叉统计发现（miss=0的行正样本率12.5% vs 全样本5.2%），随即修复：事件类别（default_year/first_consec_loss_year）一律不生成缺失指示。

Bug 2: 缩尾误伤年份列（严重）

修复缩尾"用训练集分位"时，忘了把 year 列排除——year 是数值列，被按"训练集年份分位（2019–2022）"clip，导致 2023–2025 全部被改写为2022（2022年出现21,860行异常）。通过"分步复现"定位到 winsorize 函数，修复：缩尾只作用于特征列，排除 year/label/split 等非特征列。

这两个bug的价值：它们证明项目经历了真实的数据工程检验——泄漏会让指标虚高（如果不修复，报告的AUC是假的）；而审计方法论（交叉验证统计、分步复现、特征–标签语义审查）本身就是建模能力的体现。

8.3 平台验证流程的踩坑记录

- 任务创建时 source_dir 必须是已存在目录的绝对路径；
- 验证输入契约需要确认（Web/API人工环节）：split列必须存在于**样本CSV文件**（平台从文件校验，不用notebook内存）；
- 平台只接受三类切分（train/test/oout），自定义"valid"要并入 test；
- 数据字典（特征元数据）需提供 feature/category/importance 三列，分类粒度决定压力测试质量——最初全部归"财务比率"一类导致压力测试失真（剔一类=剔全部），修复为7类后压力测试才有意义。

9. 结论、局限与展望

9.1 项目结论

1. **方法论结论**：盈利与现金流质量的恶化是比杠杆更早、更强的信用风险预警信号（IV排序、压力测试、出险画像三证据互证）；
2. **能力结论**：用T年财报预测T+1年风险事件，样本外AUC 0.882/KS 0.632，排序能力可靠；
3. **应用结论**：2026年风险最高的一批公司集中在地产链施工（陕建股份、东南网架）、周期底部（包钢、山西焦化、中盐化工）、需求萎缩的制造与零售（航天电子、天虹）——共性都是"盈利腰斩+现金流覆盖弱"。

9.2 局限（诚实清单）

- **样本覆盖**：仅现存上市公司；退市主体缺失（幸存者偏差）；城投/非上市发债主体不在范围；
- **标签代理**：首次亏损是困境早期信号，与ST/违约有时间差；违约名单是公开可验证子集（22家A股），非完整309家；
- **报表粉饰盲区**：模型基于报表数据，无法识别造假与表外负债——必须与审计意见、舆情、实地调研结合；
- **行业漂移**：地产出清后地产链权重可能下降，模型需年度重训+PSI持续监控；
- **oot的2025年行无标签**：样本外中含2025年（事件尚未发生），该部分仅作前瞻样本。

9.3 展望（V2方向）

- 接入审计意见（非标审计是强信号）；
- 舆情/NLP信号（公告文本、负面新闻）；
- 城投扩展：区域财政数据（一般公共预算收入、债务率、土地出让）；
- 违约名单扩充至完整309家（联合资信历年报告解析）；
- 模型监控体系：月度PSI/特征漂移自动告警。

10. 附录

10.1 技术栈

- Python 3.12（conda环境）；pandas/scikit-learn/xgboost；
- akshare（财务数据）、同花顺iFinD HTTP API（实控人）、巨潮（行业）；
- MARVIS-Agent v2.3.2（MIT）：验证工作流（分箱/IV/KS/PSI/压力测试/PMML一致性/报告）；
- JDK17（PMML运行时）、sklearn2pmml（PMML导出）；评分卡刻度手写。

10.2 复现步骤

```
conda activate marvis
cd zh_credit
# 1. 数据
python data_fetch.py --start-year 2019 --output data/financial_panel.csv
python label_build.py --input data/financial_panel.csv \
    --default-list data/bond_default_list.csv --output data/panel_labeled.csv
# 2. 特征
python features.py --input data/panel_labeled.csv --output data/modeling_dataset.csv
# 3. 建模+PMML导出（生成notebook并执行）
python build_modeling_notebook.py
jupyter execute notebooks/modeling.ipynb
# 4. 分析
python industry_analysis.py
python warning_list.py
# 5. 平台验证（需部署MARVIS）
bash scripts/start_marvis.sh # http://127.0.0.1:8899
# 创建验证任务（notebook+样本+PMML+字典）→ 契约确认 → marvis validate <task_id>
```

10.3 关键数字速查

项	数值
样本	5,468公司 × 7年 = 37,956行
标签	正样本1,986（5.23%）；首次亏损+22家违约名单
特征	42个 → IV筛选后25个入模
模型（测试集）	LR: AUC 0.864/KS 0.596；XGB: AUC 0.885/KS 0.639
平台验证（样本外）	AUC 0.882/KS 0.632；PMML 37,956行零失败；月度PSI 0.02
压力测试	剔除盈利类：KS 0.632→0.106
评分卡	Factor=28.85，Offset=600，分数578–807
画像	高风险行业：建筑装饰13.2%/影视11.8%/钢铁10.6%/地产10.5%

本报告所有数字均为项目实际运行结果；平台层基于开源MARVIS-Agent（MIT）二次开发，数据/标签/特征/分析/报告为作者自建。报告版本 v2.0（详细教学版）。