

# 中国发债主体信用风险预警模型 — 项目报告（详细版）

作者：章建军 | 日期：2026年8月20日 | 版本：v2.0（教学详细版）

定位：本报告面向"智力正常但对机器学习/信用分析领域较陌生的读者"，从零解释每一个概念——指标是什么、为什么选它；模型是什么原理、为什么用；评价指标怎么读；代码实现的难点在哪里。所有数字均为项目实际运行结果。

## 目录

- 项目概述：我们到底做了什么
- 数据层：从哪拿数据、怎么拿、拿多少
- 标签层：什么是"信用风险事件"，怎么定义才不算作弊
- 特征层：42个特征逐个解释
- 建模层：WOE分箱 → 逻辑回归 → 评分卡 → XGBoost
- 验证层：凭什么相信模型的结果
- 分析层：分行业画像与预警清单
- 代码实现：难点、坑、与修复
- 结论、局限与展望
- 附录：复现步骤与文件清单

# 1. 项目概述：我们到底做了什么


## 1.1 一句话版本

用中国 A股上市公司公开的财务数据，训练一个机器学习模型，预测"未来一年这家公司会不会出问题"（亏损、违约等风险事件），并给出全市场风险排名和预警名单。

## 1.2 为什么做这件事（业务背景）

- 中国债券市场存量已超120万亿元，2018年以来打破"刚兑"，违约常态化——投资者需要提前识别风险；
- 信用研究（信评）的传统做法是分析师逐家看报表、跑调研——**成本高、覆盖有限**（5000多家公司不可能都看）；
- 本项目的定位是**量化初筛**：模型把5000多家公司先筛一遍，排出风险最高的50家，分析师只需重点看这50家——"模型排序+人工终审"。

## 1.3 整体流程（一句话看懂全貌）



## 1.4 三个贯穿全程的原则

**原则一：绝不"偷看未来"（防泄漏）。**金融建模最大的陷阱是模型在训练时"看到了答案"。本项目用三套机制保证：标签时点对齐、训练集单独拟合、时间序列切分。审计中还发现并修复了一个真实的泄漏bug（见第8章）。

**原则二：可解释优先。**信用决策要承担责任，黑箱模型无法向业务方解释"为什么拒绝这笔贷款"。因此主模型用逻辑回归+评分卡——每个指标、每个分数都能讲清楚含义。

**原则三：独立验证。**自己算的指标可能自欺。项目引入开源平台 MARVIS 做"第三方"独立验证：它的内核重新计算所有指标，并校验"训练时的模型"与"要投产的模型文件"是否一致。

## 2. 数据层：从哪拿数据、怎么拿、拿多少

### 2.1 数据源（三个，各有分工）

| 数据源                 | 是什么                                                     | 本项目用途                                     |
|---------------------|---------------------------------------------------------|-------------------------------------------|
| akshare             | 开源Python库（GitHub ★22k），封装了新浪财经/东方财富等免费数据源的接口，把网页数据解析成表格 | 主力：财务指标（每家公司的历年财报数据）                      |
| 同花顺 iFinD（HTTP API） | 同花顺的金融数据接口，试用账号可用                                       | 实际控制人（判断国企/民企）——批量接口一次取20家公司，5,210家约6分钟抓完 |
| 巨潮资讯（cninfo）        | 证监会指定信息披露平台                                             | 证监会行业分类（每家公司属于哪个行业）                       |

### 2.2 样本规模

| 项     | 数值           | 说明                                            |
|-------|--------------|-----------------------------------------------|
| 公司数   | 5,468 家      | 全部A股剔除金融行业（银行/证券/保险——财务结构特殊，杠杆含义完全不同，混入会污染模型） |
| 时间范围  | 2019–2025 年报 | 7年，每年约5,400家                                  |
| 总行数   | 37,956 行     | 每行 = "一家公司 × 一个年度"的财务快照                       |
| 行业覆盖  | 89%          | 巨潮证监会分类；未覆盖的11%多为退市/新上市公司                     |
| 实控人覆盖 | 91%          | iFinD 实控人数据；用于"国企/民企"分组分析                     |

### 2.3 抓取的工程问题（真实项目的琐碎与必要）

- **为什么需要断点续跑：**5,468家公司逐家请求，每家1–3秒，全量2–3小时。中途任何网络抖动都会中断——把已完成的公司代码写进缓存文件，重启自动跳过，中断可恢复；
- **为什么限速：**akshare 底层是公共免费接口，高频请求会被对方服务器拒绝（报错 RemoteDisconnected）。每次请求间隔0.35秒，失败重试3次、退避等待；
- **数据质量实测发现：**akshare 财务接口的"销售毛利率"列对几乎所有公司返回空值（数据源问题）——实测后从特征中剔除，改用营业利润率/净利率替代。这是真实项目中"数据不是说明书说的那样"的典型情况。

### 3. 标签层：什么是"信用风险事件"，怎么定义才不算作弊

#### 3.1 机器学习需要什么

监督学习需要"输入-输出"配对：输入是财务特征，输出是**标签**（0=正常，1=出事）。标签定义直接决定模型学什么——这是全项目最核心、最花心思的部分。

#### 3.2 什么是"出事"？（标签定义）

本项目定义"信用风险事件"= 两个事件的并集：

- **首次年度亏损**：公司某年 EPS（每股收益）由正转负。为什么用这个？中国没有美国式破产制度，学术界研究中国公司财务困境的通行标志是ST（特别处理），而 ST 的核心触发条件是"连续两年亏损"。"首次亏损"是这条恶化路径的**第一步**——提前一年捕捉困境起点，这正是"预警"的意义；
- **债券违约**：公司发行的债券发生实质违约。中国债市累计违约发行人309家（联合资信统计，2012–2025），其中A股上市公司子集22家已整理进名单（如华夏幸福2021年违约、康得新2019年违约）。

#### 3.3 时点对齐：怎么定义"预测"才算数（防前视偏差）

关键事实：上市公司的年报最迟在次年4月30日披露。这意味着：

用 *T*年财报（*T*+1年4月30日前可得的信息）→ 预测 *T*+1年内发生的事件

具体实现：对每一行（公司×*T*年财报），标签 *y*=1 当且仅当"该公司首次亏损年份 == *T*+1"（或违约年份 == *T*+1）。

**如果违反会怎样？**假如用 *T*+1 年的财报去预测 *T*+1 年的事件，模型等于"偷看答案"——训练时 AUC 高达 0.95+，一上线就崩盘。这就是金融时序建模与普通机器学习的本质区别：**时间顺序本身就是数据的灵魂**。

#### 3.4 标签分布（质量检查）

| 年份（财报年）           | 2019 | 2020 | 2021 | 2022 | 2023 | 2024 | 合计               |
|-------------------|------|------|------|------|------|------|------------------|
| 正样本（ <i>y</i> =1） | 395  | 278  | 355  | 315  | 358  | 285  | 1,986<br>(5.23%) |

正样本占比5.2%——意味着平均每20家公司里约1家会在未来一年首次亏损/违约。分布均匀，没有某一年特别异常（2019年偏高与疫情前经济下行有关，属正常波动）。

## 4. 特征层：42个特征逐个解释

特征 = 模型用来做判断的"输入变量"。原始财务数据（总资产、净利润、现金流等）不能直接用（公司规模不同不可比），需要加工成比率。以下逐个解释每个指标的公式、含义、直觉方向（↑表示值越大越安全，↓表示值越大越危险）。

### 4.1 偿债能力类（6个）——公司扛不扛得住

| 指标（代码）                   | 计算公式与含义                                     | 信用分析直觉                                           |
|--------------------------|---------------------------------------------|--------------------------------------------------|
| 资产负债率 debt_ratio         | 总负债 ÷ 总资产。总资产里有多少是借来的                       | ↓ 越高越危险。但注意：行业差异大（银行90%正常，制造业70%已很高），所以模型里它是相对比较 |
| 流动比率 current_ratio       | 流动资产 ÷ 流动负债。一年内能变现的资产能否覆盖一年内要还的债            | ↑ 越高越安全。一般 >1.5 健康，<1 危险                         |
| 速动比率 quick_ratio         | (流动资产-存货) ÷ 流动负债。比流动比率更严格——存货变现慢，剔除后看"真金白银" | ↑ 越高越安全                                          |
| 现金比率 cash_ratio          | 现金及等价物 ÷ 流动负债。最保守——不靠卖资产，光靠手头现金能还多少短债       | ↑ 越高越安全                                          |
| 利息支付倍数 interest_coverage | EBIT(息税前利润) ÷ 利息费用。赚的钱是利息的几倍                | ↑ 越高越安全；<2 意味着利润快覆盖不住利息了                         |
| 产权比率 equity_ratio        | 总负债 ÷ 所有者权益。杠杆的另一视角：借的钱是股东本金的几倍             | ↓ 越高越危险                                          |

### 4.2 盈利能力类（7个）——公司赚不赚钱

| 指标                        | 计算公式与含义                                     | 信用分析直觉                              |
|---------------------------|---------------------------------------------|-------------------------------------|
| 净资产收益率 ROE                | 净利润 ÷ 净资产。股东每投入1元赚多少——全项目区分力最强的指标 (IV=0.99) | ↑ 越高越安全；出险公司中位数3.4% vs 正常公司7.7%（腰斩） |
| 总资产净利润率 ROA               | 净利润 ÷ 总资产。不分股东债权人，全部资产的赚钱效率                 | ↑ 越高越安全                             |
| 销售净利率 net_margin          | 净利润 ÷ 营业收入。每100元收入最后剩多少利润                   | ↑ 越高越安全；出险公司4.3% vs 正常8.1%          |
| 营业利润率 op_margin           | 营业利润 ÷ 营业收入。主业（不含投资收益/政府补助）的利润率             | ↑ 越高越安全                             |
| 成本费用利润率 cost_profit_ratio | 利润总额 ÷ (营业成本+费用)。花出去的每1元成本换回多少利润            | ↑ 越高越安全                             |
| 每股收益 EPS                  | 净利润 ÷ 总股本。每1股赚多少——亏损判定（标签）的直接依据，IV=0.98     | ↑ 越高越安全；<0 即亏损                      |

|           |                      |         |
|-----------|----------------------|---------|
| 每股净资产 BPS | 净资产 ÷ 总股本。每1股背后有多少家底 | ↑ 越高越安全 |
|-----------|----------------------|---------|

4.3 现金流质量类（5个）——赚的钱是不是真钱（信评核心逻辑）

为什么现金流单独成类？信用分析的第一原则：**利润是会计判断，现金是事实**。公司可以"做出"利润（赊销、提前确认收入），但现金流骗不了人。经营现金流与利润长期背离的公司，往往是报表粉饰的高危对象。

| 指标                         | 计算公式与含义                                                                            | 信用分析直觉                           |
|----------------------------|------------------------------------------------------------------------------------|----------------------------------|
| 每股经营现金流<br>ocf_per_share   | 经营活动现金流净额 ÷ 总股本。经营赚到的真金白银，每股摊多少                                                    | ↑ 越高越安全                          |
| 经营现金流/销售收入<br>ocf_to_sales | 经营现金流 ÷ 营业收入。每100元收入，有多少变成了真实现金                                                    | ↑ 越高越安全；长期偏低=利润可能是"纸面利润"         |
| 经营现金流/净利润<br>ocf_to_ni     | 经营现金流 ÷ 净利润。 <b>利润的"含金量"指标</b> ——大于1说明利润全部变现，小于1说明利润没收到钱（应收堆积/存货积压）。IV=0.57，模型重点依赖 | ↑ 越高越安全；长期 <1 是重大警示（信评必看指标）      |
| 经营现金流/负债<br>ocf_to_debt    | 经营现金流 ÷ 总负债。靠经营造血一年能覆盖多少债务                                                         | ↑ 越高越安全；出险公司0.068 vs 正常0.140（减半） |
| 现金流量比率<br>cashflow_ratio   | 经营现金流 ÷ 流动负债。经营现金流对短债的覆盖                                                           | ↑ 越高越安全                          |

4.4 营运效率类（3个）——资产转不转得动

| 指标                       | 计算公式与含义                       | 信用分析直觉                  |
|--------------------------|-------------------------------|-------------------------|
| 应收账款周转率<br>ar_turnover   | 营业收入 ÷ 平均应收账款。应收账款一年转几圈（回款速度） | ↑ 越高越安全；周转放慢=客户拖欠=资金被占用 |
| 存货周转率 inv_turnover       | 营业成本 ÷ 平均存货。存货一年卖几轮           | ↑ 越高越安全；存货积压=滞销=占用资金    |
| 总资产周转率<br>asset_turnover | 营业收入 ÷ 总资产。全部资产的"出活"效率        | ↑ 越高越安全；持续下降=资产效率恶化     |

4.5 成长类（3个）+ 规模（1个）

| 指标                     | 计算公式与含义           | 信用分析直觉                            |
|------------------------|-------------------|-----------------------------------|
| 营收增长率 rev_growth       | 本年营收 ÷ 上年营收 - 1   | ↑ 一般越高越好，但异常高增长也可能是激进扩张信号（结合现金流看） |
| 净利润增长率 ni_growth       | 本年净利 ÷ 上年净利 - 1   | ↑ 越高越好                            |
| 总资产增长率<br>asset_growth | 本年总资产 ÷ 上年总资产 - 1 | ↑ 过高警惕"过度扩张+高杠杆扩张"                |

|                         |                                              |                           |
|-------------------------|----------------------------------------------|---------------------------|
| 总资产（对数）<br>total_assets | ln(总资产)。规模量级；取对数是因为资产跨数量级（亿到万亿），log压缩量纲让模型更稳 | ↑ 越大越安全（规模效应与"大而不倒"的隐性担保） |
|-------------------------|----------------------------------------------|---------------------------|

4.6 趋势特征Δ（6个）——"趋势比水平更重要"

对6个核心指标构造**同比变化**：如 `debt_ratio_delta = 今年负债率 - 去年负债率`。直觉：一个负债率从40%一年飙到65%的公司，比一直65%的公司更危险——**恶化速度是重要信号**。这6个：资产负债率Δ、ROEΔ、经营现金流/净利润Δ、流动比率Δ、净利率Δ、总资产周转率Δ。

4.7 缺失指示变量（\_miss, 11个）

缺失率超过5%的列，额外生成一个0/1列标记"该指标是否缺失"。原理：**缺失本身是信息**——指标没披露的公司往往有问题（比如某公司连续不披露经营现金流）。

4.8 特征筛选结果（IV 排序，模型最终只用了25个）

| 特征        | IV    | 含义解读                                             |
|-----------|-------|--------------------------------------------------|
| ROE       | 0.987 | IV TOP 被盈利类霸榜—— <b>盈利质量是最强的预警信号</b> ，与信用分析理论完全一致 |
| EPS       | 0.976 |                                                  |
| ROA       | 0.954 |                                                  |
| 净利率       | 0.599 |                                                  |
| 成本费用利润率   | 0.592 |                                                  |
| 经营现金流/净利润 | 0.571 | 现金流含金量——第二大信号源                                   |
| 利息支付倍数    | 0.379 | 偿债缓冲                                             |
| 净利润增长率    | 0.360 | 盈利趋势                                             |



## 5. 建模层：WOE分箱 → 逻辑回归 → 评分卡 → XGBoost

### 5.1 第一步：WOE 分箱（把连续数字变成"风险档位"）

#### 5.1.1 问题：为什么不能直接用原始数字？

以负债率为例：模型要学的不是"负债率=76.3%"这个精确数字，而是"负债率处于哪个风险区间"。原因有三：

1. **非线性**：负债率从30%→60%风险缓升，60%→90%风险陡升——直线模型表达不了这种"S型"关系，分箱后用分段常数逼近非线性；
2. **稳健性**：76.3%和76.4%其实没有区别，分箱让模型不被微小波动干扰；
3. **可解释**：分箱后每个区间可以直接读（"负债率70–90%这档风险高"）。

#### 5.1.2 WOE 是什么（证据权重）

把每个特征分成若干箱（本项目等频分箱，10箱），每箱计算：

$$WOE_i = \ln( \text{箱内坏样本占比} / \text{箱内好样本占比} ) = \ln( (b_i/B) / (g_i/G) )$$

其中  $b_i/g_i$  是第  $i$  箱内坏/好样本数， $B/G$  是总体坏/好样本数。直觉：**WOE>0** 表示这箱的"坏浓度"高于整体（更危险），**WOE<0** 表示更安全。WOE 把"负债率 76%"翻译成"风险贡献度 +0.8"——单调、有界、可比。

#### 5.1.3 实现细节（代码难点，第8章详述）

- 缺失值单独成箱（缺失是信息）；
- WOE 平滑：某箱坏样本为0时  $\ln$  无定义，分子分母各加0.5（拉普拉斯平滑）；
- 分箱只用训练集拟合（防止"看到"验证集）；
- 验证/测试集出现训练集没见过的新数值时，编码为WOE=0（中性处理，不报错）。

### 5.2 第二步：IV 筛选（哪些特征值得进模型）

$$IV = \sum_i (\text{坏占比}_i - \text{好占比}_i) \times WOE_i$$

IV 度量一个变量"区分好坏的能力"（可以理解为 WOE 的加权和）。经验阈值：IV<0.02 无预测力（剔除）；0.02–0.1 弱；0.1–0.3 中等；>0.3 强。本项目 42 个特征筛出 25 个（IV>0.02）。

### 5.3 第三步：逻辑回归（主模型）

#### 5.3.1 原理（一步步来）

逻辑回归解决的是"预测0/1"问题。它从线性回归出发：线性回归预测连续值  $y = \beta_0 + \beta_1 x_1 + \dots + \beta_n x_n$ ，但我们要预测的是概率（0到1之间）。于是把线性结果塞进 **Sigmoid 函数**：

$$P(y=1|x) = 1 / (1 + e^{-(\beta_0 + \beta_1 \cdot WOE_1 + \dots + \beta_n \cdot WOE_n)})$$

Sigmoid 把任意实数压缩到(0,1)，变成概率。等价写法（**logit 变换**）：

$$\ln( \text{odds} ) = \beta_0 + \beta_1 \cdot WOE_1 + \dots + \beta_n \cdot WOE_n, \text{ 其中 } \text{odds} = P/(1-P)$$

即：模型学的是"风险对数的线性组合"。训练方法：极大似然估计——找到一组系数  $\beta$ ，使得"对正样本预测的概率高、对负样本预测的概率低"。

5.3.2 为什么选逻辑回归当主模型

- 1. 可解释：系数  $\beta_i$  直接读——"经营现金流/净利润恶化一箱，风险对数变化多少"；
- 2. 天然适配 WOE：WOE 变换后特征与 log-odds 近似线性，LR 是最佳搭档（这也是评分卡行业的标准组合）；
- 3. 监管友好：银行风控和监管机构要求模型可解释、可审计，LR+评分卡是行业默认答案。

5.4 第四步：评分卡刻度（把概率翻译成人话）

银行不用概率审批（"违约概率0.031"没人有感觉），用分数（"680分以上通过"）。转换公式：

$$Score = Offset + Factor \times \ln(odds)$$

- 锚点设置：odds=1:1 时 600 分；odds 翻倍分数 +20 分（PDO=20）；
- 推导：Factor = PDO/ln(2) = 20/0.693 = **28.85**；Offset = 600 - 28.85×ln(1) = **600**；
- 本项目分数范围 578–807（训练集），分数越高风险越低——可以直接划准入线（如"650分以下进入人工复核"）。

5.5 第五步：XGBoost（对照模型，效果更优）

5.5.1 原理

XGBoost 是梯度提升决策树：由许多棵"小树"组成加法模型，逐棵训练，每棵新树专门拟合前面所有树的"残差"（错误）：

$$\hat{y} = f_1(x) + f_2(x) + \dots + f_n(x)$$

第 t 轮：先用当前模型预测，计算每个样本的残差（真实值-预测值），然后训练一棵新树  $f_t$  去拟合残差——相当于"哪里错了补哪里"。每轮目标函数：

$$Obj = \sum 损失(y_i, \hat{y}_i) + \sum 正则(树的复杂度)$$

工程上的三个关键创新：

- 二阶泰勒展开：对损失函数做二阶近似，比普通梯度提升（只用一阶）收敛更快更准；
- 分裂增益公式：每次分裂选择"增益最大"的特征和切分点，带正则项（叶子数、叶子权重）防过拟合；
- 原生处理缺失值：分裂时自动学习"缺失值走左还是右"——本项目 XGB 直接吃含缺失的原始特征，不需要预先填充。

5.5.2 项目中的参数（每个参数为什么这么设）

| 参数            | 值       | 理由                                                       |
|---------------|---------|----------------------------------------------------------|
| n_estimators  | 300（固定） | 固定轮数而非早停——保证"训练时的模型"与"导出PMML重训的模型"完全一致（平台一致性验证要求，见第6/8章） |
| max_depth     | 3       | 浅树防过拟合（树太深就记住了训练集）                                       |
| learning_rate | 0.05    | 小步慢走：每棵树只贡献一点点，靠300棵树累积，更稳                               |

|                              |           |                                              |
|------------------------------|-----------|----------------------------------------------|
| subsample / colsample_bytree | 0.8 / 0.8 | 行/列随机采样（类似随机森林思想），每棵树看到不同子集，增强泛化             |
| scale_pos_weight             | ≈16       | 正样本只占5.2%，给正样本加权（负/正比），等价于少数类过采样，防止模型"全都预测0" |
| n_jobs=1, random_state=42    | —         | 确定性训练：同样的输入永远同样的输出（PMML一致性前提）                |

5.5.3 为什么"双模型"

LR 可解释但表达力有限；XGB 效果好（测试集 AUC 0.885 vs LR 0.864）但是黑箱。业界真实做法是**两者并存**：XGB 用于自动化初筛（量大、要效果），LR评分卡用于需要解释的环节（监管、人工复核）。本项目主交付是可解释链路，XGB 作对照并承担平台投产验证（PMML 工程可行性）。

5.6 模型结果（本地评估）

| 模型      | 训练集 AUC/KS    | 验证集 AUC/KS    | 测试集 AUC/KS           |
|---------|---------------|---------------|----------------------|
| WOE逻辑回归 | 0.815 / 0.477 | 0.820 / 0.487 | <b>0.864 / 0.596</b> |
| XGBoost | 0.912 / 0.673 | 0.850 / 0.555 | <b>0.885 / 0.639</b> |

观察：训练集与测试集指标接近（甚至测试更好）——**没有过拟合**；测试集（2024年）略优于验证集（2023年），因为2024年事件特征更清晰（地产出清尾声、亏损公司财务恶化更彻底）。

## 6. 验证层：凭什么相信模型的结果

### 6.1 时间序列切分（为什么不用随机划分）

常规机器学习用随机抽样划分训练/测试集。金融数据**不行**：同一家公司的相邻年份高度相关（2020年亏损的公司2021年大概率还差），随机划分等于把"邻居"分别放进训练和测试——模型其实见过类似样本，指标虚高。正确做法：

时间线（财报年）：2019 2020 2021 2022 | 2023 | 2024+2025  
                                    └── 训练 ──┘   └─ 验证 ─┘└─ 样本外 ─┘  
训练：拟合模型；验证：调参（只看一次）；样本外：最终检验（模型从未见过）

### 6.2 评估指标逐个解释

#### AUC（曲线下面积）

最直观的解释：随机抽一个"真出事"的公司和一个"真没事"的公司，模型给前者打分更高的概率。0.5=瞎猜（抛硬币），0.7=可用，0.8=强区分，0.9+=极强。本项目测试集 XGB AUC=0.885——意思是约88.5%的情况下，模型能把"出事的"排在"没事的"前面。

#### KS（Kolmogorov-Smirnov）

把所有公司按模型分数从低到高排序，画两条累计曲线：坏样本占比、好样本占比。两条曲线的**最大间距**就是KS：

$$KS = \max | \text{坏样本累计占比} - \text{好样本累计占比} |$$

直觉：KS=0.64 意味着在最优切点处，模型能分离出64%的"好坏分布差距"。信贷行业标准：KS>0.3 可用，>0.4 优秀，>0.6 极强（但过高要警惕过拟合）。

#### PSI（群体稳定性指数）

模型上线后会"漂移"吗？PSI 比较两个时期分数分布的差异：

$$PSI = \sum (\text{实际占比} - \text{预期占比}) \times \ln(\text{实际占比} / \text{预期占比})$$

阈值：<0.1 稳定；0.1-0.25 需关注；>0.25 需重建模型。本项目月度 PSI vs 训练 = **0.02**——2023-2025年评分分布几乎没变，模型稳定。

#### IV（见5.2）

变量区分度，用于特征筛选。

### 6.3 平台独立验证（MARVIS：让第二套独立计算来背书）

MARVIS 是开源风控建模验证平台（MIT协议）。它的作用不是建模，而是**验证**：

- Notebook 契约**：建模notebook必须在顶层暴露统一接口（样本、标签列、打分函数、算法名）——强制"模型可复现、可调用"，杜绝模型藏在代码角落的演示型项目；
- 独立计算**：平台用自己实现的确定性内核，对模型重新计算 KS/AUC/PSI/分箱/压力测试——**两套独立代码算出相近结果才算数**（本地 0.885 vs 平台 0.882，互相印证）；

3. **PMML 一致性**：把训练好的模型导出为标准 PMML 文件（模型上线时的实际交付格式），平台逐行比对"内存模型打分"与"PMML文件打分"——37,956行**零失败**，证明"我训练的模型"和"我声称要投产的文件"是同一个；
4. **压力测试**：按特征类别整类剔除后重算 KS，看模型对哪类特征"上瘾"：

| 剔除的特征类别 | 剔除后 KS | KS 变化  | 解读               |
|---------|--------|--------|------------------|
| （基线）    | 0.632  | —      | 样本外基线            |
| 盈利类     | 0.106  | −0.526 | 模型核心依赖盈利质量——符合理论 |
| 偿债类     | 0.609  | −0.023 | 次要但真实贡献          |
| 现金流类    | 0.620  | −0.011 | 次要贡献             |
| 成长类     | 0.628  | −0.004 | 弱贡献              |

6.4 平台验证的最终成绩单

| 数据集            | AUC                  | KS    | 说明                      |
|----------------|----------------------|-------|-------------------------|
| 训练（2019–2022）  | 0.912                | 0.671 | 平台独立计算                  |
| 开发验证（2023）     | 0.850                | 0.555 | 平台独立计算                  |
| 样本外（2024+2025） | 0.882                | 0.632 | 平台独立计算（2025年行为"未来"前瞻样本） |
| PMML一致性        | 37,956 行全部成功、零失败、零空值 |       |                         |
| 月度PSI vs 训练    | 0.02（优秀线 0.1）        |       |                         |

## 7. 分析层：分行业风险画像与预警清单

### 7.1 方法一：透视表（行业×年份风险矩阵）

把样本按"行业×年份"分组，计算每组的风险事件发生率（正样本比例）。结果（2019–2024整体风险率TOP10）：

| 行业                    | 风险率      | 解读              |
|-----------------------|----------|-----------------|
| 建筑装饰、装修               | 13.2%    | 地产链：垫资施工、应收高企   |
| 广播、电视、电影              | 11.8%    | 可选消费 + 高经营杠杆    |
| 黑色金属冶炼（钢铁）            | 10.6%    | 周期下行、产能过剩       |
| 房地产业                  | 10.5%    | 2021–2024违约潮主战场 |
| 商务服务/公共设施/软件/文教/环保/纺织 | 8.1–8.9% | 弱现金流、可选属性       |

发现：高风险行业=地产链 + 周期 + 弱现金流行业，与中国债市实际违约分布完全吻合。

### 7.2 方法二：出险画像（出险 vs 正常公司的指标中位数对比）

把"未来一年出险"的公司（出险前一年的财报）与正常公司分组，比较各指标**中位数**（为什么用中位数？财务指标右偏、极端值多，均值易被污染，中位数稳健）：

| 指标       | 出险公司  | 正常公司  | 差异    |
|----------|-------|-------|-------|
| ROE(%)   | 3.37  | 7.74  | 腰斩    |
| 净利率(%)   | 4.26  | 8.11  | 腰斩    |
| 每股收益(元)  | 0.18  | 0.40  | 腰斩    |
| 经营现金流/负债 | 0.068 | 0.140 | 减半    |
| 资产负债率(%) | 40.1  | 39.8  | 几乎无差异 |
| 流动比率     | 1.82  | 1.84  | 几乎无差异 |

**核心结论：盈利与现金流质量的恶化是比杠杆更早、更强的预警信号。**杠杆类水平指标在出险前几乎无区分度——因为上市公司普遍在报表层面维持杠杆指标；而盈利与现金流的恶化先于违约发生。这条结论被三套独立证据支持：IV排序（盈利类霸榜）、压力测试（剔盈利类模型崩溃）、画像统计（盈利腰斩）——三个证据指向同一个规律，这是建模可信度的最高形态。

### 7.3 所有制维度

- 民企风险率 6.5% > 国企 5.8% > 无实控人 4.3%；
- 与联合资信统计一致（2025年新增违约主体69%为民营企业）；

- 高风险组合示例：畜牧业民企16.7%（正邦、雏鹰等养殖周期股）、钢铁国企13.5%（行业周期而非所有制）、地产国企10.8%。

### 7.4 预警清单 TOP50（模型的实际输出）

对最新一期（2025年报）全样本打分，取风险最高50家，并按画像规则标注主要风险特征（阈值来自7.2的中位数）。TOP10：

| 代码     | 名称   | 行业     | 所有制 | 预警概率  | 主要风险特征                  |
|--------|------|--------|-----|-------|-------------------------|
| 920931 | 无锡鼎邦 | 专用设备   | —   | 0.944 | ROE<3%；净利率<4%；现金流/负债<5% |
| 300342 | 天银机电 | 通用设备   | 民企  | 0.942 | ROE<3%；净利率<4%；现金流覆盖弱    |
| 600248 | 陕建股份 | 土木工程建筑 | 国企  | 0.936 | 盈利双低；现金流覆盖弱；负债率>70%     |
| 600740 | 山西焦化 | 焦化     | 国企  | 0.932 | 盈利双低；现金流覆盖弱             |
| 600328 | 中盐化工 | 化学原料   | 国企  | 0.925 | 盈利双低；现金流覆盖弱             |
| 600510 | 黑牡丹  | 房地产    | 民企  | 0.922 | 盈利双低；现金流覆盖弱             |
| 600010 | 包钢股份 | 钢铁     | 国企  | 0.915 | 盈利双低；现金流覆盖弱             |
| 002419 | 天虹股份 | 零售     | 国企  | 0.915 | 盈利双低；负债率>70%            |
| 002135 | 东南网架 | 金属制品   | 民企  | 0.920 | 盈利双低；现金流覆盖弱             |
| 688075 | 安旭生物 | 医药     | 民企  | 0.925 | ROE<3%；现金流覆盖弱           |

名单结构：民企占72%；行业集中在软件/电气机械/建筑/钢铁化工——与画像结论完全自洽；90%+的公司同时命中"盈利双低"与"现金流覆盖弱"——这就是模型学到的规律：盈利腰斩+利润不变现。

名单的使用边界（诚实声明）：① 预警概率是"风险事件（首次亏损/违约）"概率，不是违约概率——违约是更小的尾部；② 排序可信、断言不可信（测试集AUC 0.885证明排序有效，但不能说某家"一定违约"）；③ 模型看不见报表粉饰与表外负债——名单的正确用法是"启动人工尽调"，不是"直接定罪"；④ 城投/非上市主体不在样本。

## 8. 代码实现：难点、坑、与修复

### 8.1 工程难点总览

| 难点           | 问题本质                                                         | 解决方案                                          |
|--------------|--------------------------------------------------------------|-----------------------------------------------|
| 全量抓取中断       | 5,468家x网络请求，2-3小时，任何抖动都会失败                                   | 断点续跑（缓存已完成代码）+ 限速0.35s + 失败重试3次退避             |
| 代码前导零丢失      | 股票代码"000002"被 pandas 读成整数2                                   | read_csv 强制 dtype=str + zfill(6)              |
| WOE分箱索引错乱    | pd.cut 后 groupby().groups 返回的是原始索引而非位置索引，误用位置索引导致 IndexError | 直接用 groups 返回的索引取值（调试两次定位）                    |
| 布尔取反的隐蔽bug   | 含NaN的列 fillna(False) 后是 object 类型，~ 取反行为异常                   | 显式 .astype(bool) 后再取反                         |
| 测试集值超出训练分箱边界 | pd.cut 对边界外的值返回 NaN → 模型收到空值报错                               | 编码后 fillna(0.0)——边界外值按"无信息"（WOE=0）处理，业界标准做法   |
| 评分卡刻度        | 分数映射公式推导与实现                                                  | Score = Offset + Factor×ln(odds), PDO=20锚点600 |
| PMML与内存模型不一致 | PMML重训若用早停，轮数不确定→与内存模型不同→一致性验证失败                             | 固定300轮 + n_jobs=1 + 固定种子（确定性训练）               |
| macOS缺Java   | PMML评分运行时（pypmml）需要Java，本机没有                                 | 下载OpenJDK17（清华镜像180MB）并设置JAVA_HOME            |

### 8.2 审计发现的两个真实bug（本报告最诚实的部分）

#### Bug 1: 标签泄漏（严重）

特征工程中"缺失率>5%的列自动生成缺失指示变量"的规则，把**违约名单年份列（default\_year）**也生成了缺失指示——而该列的缺失与否**恰好精确标记"这家公司在不在违约名单里"**（56行default\_year\_miss=0全是违约公司）。模型如果学到这个特征，等于直接"记住名单"而不是学习财务规律。审计时通过交叉统计发现（miss=0的行正样本率12.5% vs 全样本5.2%），随即修复：事件类别（default\_year/first\_consec\_loss\_year）一律不生成缺失指示。

#### Bug 2: 缩尾误伤年份列（严重）

修复缩尾"用训练集分位"时，忘了把 year 列排除——year 是数值列，被按"训练集年份分位（2019–2022）"clip，导致 2023–2025 全部被改写为2022（2022年出现21,860行异常）。通过"分步复现"定位到 winsorize 函数，修复：缩尾只作用于特征列，排除 year/label/split 等非特征列。

**这两个bug的价值：**它们证明项目经历了真实的数据工程检验——泄漏会让指标虚高（如果不修复，报告的AUC是假的）；而审计方法论（交叉验证统计、分步复现、特征–标签语义审查）本身就是建模能力的体现。



### 8.3 平台验证流程的踩坑记录

- 任务创建时 source\_dir 必须是已存在目录的绝对路径；
- 验证输入契约需要确认（Web/API人工环节）：split列必须存在于**样本CSV文件**（平台从文件校验，不用notebook内存）；
- 平台只接受三类切分（train/test/oout），自定义"valid"要并入 test；
- 数据字典（特征元数据）需提供 feature/category/importance 三列，分类粒度决定压力测试质量——最初全部归"财务比率"一类导致压力测试失真（剔一类=剔全部），修复为7类后压力测试才有意义。

## 9. 结论、局限与展望

---

### 9.1 项目结论

1. **方法论结论**：盈利与现金流质量的恶化是比杠杆更早、更强的信用风险预警信号（IV排序、压力测试、出险画像三证据互证）；
2. **能力结论**：用T年财报预测T+1年风险事件，样本外AUC 0.882/KS 0.632，排序能力可靠；
3. **应用结论**：2026年风险最高的一批公司集中在地产链施工（陕建股份、东南网架）、周期底部（包钢、山西焦化、中盐化工）、需求萎缩的制造与零售（航天电子、天虹）——共性都是"盈利腰斩+现金流覆盖弱"。

### 9.2 局限（诚实清单）

- **样本覆盖**：仅现存上市公司；退市主体缺失（幸存者偏差）；城投/非上市发债主体不在范围；
- **标签代理**：首次亏损是困境早期信号，与ST/违约有时间差；违约名单是公开可验证子集（22家A股），非完整309家；
- **报表粉饰盲区**：模型基于报表数据，无法识别造假与表外负债——必须与审计意见、舆情、实地调研结合；
- **行业漂移**：地产出清后地产链权重可能下降，模型需年度重训+PSI持续监控；
- **oot的2025年行无标签**：样本外中含2025年（事件尚未发生），该部分仅作前瞻样本。

### 9.3 展望（V2方向）

- 接入审计意见（非标审计是强信号）；
- 舆情/NLP信号（公告文本、负面新闻）；
- 城投扩展：区域财政数据（一般公共预算收入、债务率、土地出让）；
- 违约名单扩充至完整309家（联合资信历年报告解析）；
- 模型监控体系：月度PSI/特征漂移自动告警。

## 10. 附录

### 10.1 技术栈

- Python 3.12（conda环境）；pandas/scikit-learn/xgboost；
- akshare（财务数据）、同花顺iFinD HTTP API（实控人）、巨潮（行业）；
- MARVIS-Agent v2.3.2（MIT）：验证工作流（分箱/IV/KS/PSI/压力测试/PMML一致性/报告）；
- JDK17（PMML运行时）、sklearn2pmml（PMML导出）；评分卡刻度手写。

### 10.2 复现步骤

```
conda activate marvis
cd zh_credit
# 1. 数据
python data_fetch.py --start-year 2019 --output data/financial_panel.csv
python label_build.py --input data/financial_panel.csv \
    --default-list data/bond_default_list.csv --output data/panel_labeled.csv
# 2. 特征
python features.py --input data/panel_labeled.csv --output data/modeling_dataset.csv
# 3. 建模+PMML导出（生成notebook并执行）
python build_modeling_notebook.py
jupyter execute notebooks/modeling.ipynb
# 4. 分析
python industry_analysis.py
python warning_list.py
# 5. 平台验证（需部署MARVIS）
bash scripts/start_marvis.sh # http://127.0.0.1:8899
# 创建验证任务（notebook+样本+PMML+字典）→ 契约确认 → marvis validate <task_id>
```

### 10.3 关键数字速查

| 项         | 数值                                             |
|-----------|------------------------------------------------|
| 样本        | 5,468公司 × 7年 = 37,956行                         |
| 标签        | 正样本1,986（5.23%）；首次亏损+22家违约名单                   |
| 特征        | 42个 → IV筛选后25个入模                               |
| 模型（测试集）   | LR: AUC 0.864/KS 0.596；XGB: AUC 0.885/KS 0.639 |
| 平台验证（样本外） | AUC 0.882/KS 0.632；PMML 37,956行零失败；月度PSI 0.02  |
| 压力测试      | 剔除盈利类：KS 0.632→0.106                           |
| 评分卡       | Factor=28.85，Offset=600，分数578–807              |
| 画像        | 高风险行业：建筑装饰13.2%/影视11.8%/钢铁10.6%/地产10.5%        |

本报告所有数字均为项目实际运行结果；平台层基于开源MARVIS-Agent（MIT）二次开发，数据/标签/特征/分析/报告为作者自建。报告版本 v2.0（详细教学版）。